LAPORAN TUGAS BESAR
PEMROSESAN BAHASA
ALAMI

Disusun untuk memenuhi tugas besar mata
kuliah CII4G3 - Pemrosesan Bahasa Alami

Disusun Oleh :

M. Luthfi Aditya Gunandi	1301213239

S1 INFORMATIKA

FAKULTAS

INFORMATIKA

TELKOM UNIVERSITY

BANDUNG

2024

A. Konsep Dasar

1. Prompting

Prompting adalah teknik dalam pengolahan bahasa alami (NLP) di mana instruksi atau konteks diberikan kepada model bahasa besar (Large Language Model, LLM) untuk menghasilkan respons yang relevan dan sesuai dengan tugas yang diberikan. Teknik ini sangat penting untuk berbagai aplikasi NLP, seperti penjawaban pertanyaan, terjemahan bahasa, dan generasi teks. Prompting memungkinkan pengguna memanfaatkan kemampuan LLM secara efektif.

Desain Prompt: Kejelasan dan spesifisitas instruksi sangat berpengaruh pada kinerja prompt. Sebuah perintah yang baik harus mampu:

1. Mengurangi Ketegangan: Instruksi yang jelas dan spesifik membantu model memahami konteks dengan lebih baik, sehingga mengurangi kemungkinan kesalahan interpretasi.
2. Memfokuskan Respons: Prompt dapat membantu model fokus pada komponen penting dari tugas yang diberikan dengan memberikan arahan yang tepat.
3. Menentukan Konteks: Memberikan informasi atau latar belakang tambahan dapat membantu model menghasilkan jawaban yang lebih tepat dan sesuai.

Jenis-jenis Prompting:

1. Direct Prompting :
   Deskripsi: Melibatkan pertanyaan atau instruksi langsung tanpa konteks.
   Contoh: "Apa ibukota Perancis?" Kelebihan: Cepat dan langsung ke tujuan, cocok untuk pertanyaan atau perintah sederhana.
   Kekurangan: Tidak cocok untuk tugas yang kompleks atau membutuhkan konteks tambahan.

2. Contextual Prompting :
   Deskripsi: Memberikan konteks tambahan untuk memperjelas petunjuk atau pertanyaan.
   Sebagai contoh, apa ibu kota Perancis dalam konteks geografi Eropa?"
   Keuntungan: Membantu model memahami latar belakang atau detail yang mungkin relevan sehingga mereka dapat membuat pilihan yang lebih akurat.
   Kekurangan: Membutuhkan usaha tambahan untuk membuat prompt yang tepat.

3. Narrative Prompting :
   Deskripsi: Menggunakan cerita atau skenario untuk membantu model menghasilkan respons.
   Sebagai contoh, "Seorang wisatawan ingin mengunjungi menara Eiffel di kota terkenal di Perancis. Apa nama kota itu?"
   Kelebihan: Sangat efektif untuk tugas kreatif atau yang membutuhkan pemahaman konteks yang lebih luas.
   Kekurangan: Jika tidak dirancang dengan baik, dapat menjadi terlalu kompleks atau membingungkan.

Pentingnya Prompting, Prompting yang baik dan tepat dapat meningkatkan kinerja dan akurasi model bahasa dalam menghasilkan respons secara signifikan. Beberapa komponen penting dari arahan adalah:

- Adaptabilitas: Prompting memungkinkan pengguna menyesuaikan instruksi sesuai dengan tugas yang diinginkan dengan cepat tanpa memerlukan perubahan model yang mendasar.
- Fleksibilitas: Dapat digunakan untuk berbagai jenis tugas pemrosesan bahasa natural (NLP), mulai dari yang sederhana hingga yang rumit.
- Efisiensi: Model dapat diarahkan untuk memahami dan menyelesaikan tugas baru dengan instruksi cepat, yang mengurangi kebutuhan untuk pelatihan tambahan.

Dengan memahami teori dan aplikasi prompting, kita dapat memanfaatkan model bahasa besar dengan lebih efektif untuk berbagai aplikasi NLP, meningkatkan akurasi dan relevansi respons yang dihasilkan. Prompting memungkinkan eksplorasi dan penerapan model bahasa besar secara lebih luas dan fleksibel dalam berbagai domain dan tugas

2. Zero-Shot Learning

Zero-shot learning sangat bergantung pada kemampuan model untuk menggeneralisasi pengeterangan. Dalam Large Language Models (LLM), ini berarti bahwa model dapat memahami dan menyelesaikan tugas yang belum pernah dilihat atau dilatih sebelumnya hanya berdasarkan deskripsi atau instruksi tugas tersebut.

Prinsip Dasar:

- Generalisasi Pengetahuan: Model yang lebih besar dan lebih kompleks seperti GPT-3 dan GPT-4 dilatih pada data yang sangat luas, sehingga mereka dapat menggeneralisasi dan menggunakan pengetahuan yang diperoleh selama pelatihan untuk membuat prediksi atau menghasilkan output pada tugas yang baru dan belum diketahui.
- Pemahaman Instruksi: Model harus dapat memahami dan menafsirkan instruksi atau deskripsi tugas dengan tepat agar pengajaran zero-shot efektif. Ini biasanya melibatkan memahami konteks dan menerapkan pola yang telah dipelajari dari data pelatihan.
- Adaptabilitas: Model harus dapat disesuaikan dan fleksibel untuk menggunakan pengetahuan yang relevan untuk tugas yang belum pernah dilihat sebelumnya. Ini juga harus memiliki kemampuan untuk menemukan pola dan hubungan antara apa yang telah dipelajari sebelumnya.

Keuntungan Zero-Shot Learning:

- Efektivitas Waktu dan Sumber Daya: Pelatihan ulang tidak diperlukan karena lebih cepat dan hemat biaya.
- Fleksibilitas: Tidak perlu mengubah model secara menyeluruh untuk diterapkan pada berbagai tugas.
- Kemampuan Generalisasi: Ini menunjukkan bahwa model telah berhasil belajar dari data yang luas dan beragam dan memiliki kemampuan untuk memahami dan menerapkan pengetahuan secara luas.

Tantangan Zero-Shot Learning:

- Keterbatasan Pemahaman Konteks: Model mungkin kesulitan memahami konteks yang sangat khusus atau tidak biasa.
- Ketidakakuratan: Jika dibandingkan dengan model yang dilatih secara khusus untuk tugas tersebut, risiko memberikan jawaban yang kurang tepat atau relevan.
- Keterbatasan Pengetahuan: Meskipun LLM memiliki pengetahuan yang luas, mereka mungkin tidak memiliki informasi terbaru atau khusus yang tidak termasuk dalam data pelatihan mereka.

Pemahaman mendalam tentang zero-shot learning memungkinkan kita untuk memanfaatkan model bahasa besar dengan lebih efisien untuk berbagai aplikasi, meningkatkan efisiensi dan fleksibilitas dalam menyelesaikan tugas-tugas yang belum pernah dilatih secara eksplisit. Pemahaman zero-shot learning memungkinkan pengembangan aplikasi NLP yang fleksibel dan hemat sumber daya.

3. Few-shot learning

Few-shot learning adalah kemampuan model untuk memahami dan menyelesaikan tugas baru dengan sedikit contoh pelatihan. Dalam jenis pelatihan ini, model diberi beberapa contoh atau contoh terbatas dalam prompt untuk membantunya memahami pola atau fitur yang diperlukan untuk tugas yang dihadapi. Meskipun jumlah contoh yang tersedia sangat terbatas, model tetap dapat mengenali pola dan menerapkannya pada tugas yang serupa.

Prinsip Dasar:

- Pembelajaran dari contoh terbatas: Pembelajaran dari contoh terbatas memanfaatkan beberapa contoh spesifik yang diberikan dalam prompt untuk membimbing model dalam menghasilkan output yang sesuai dengan pola yang diinginkan. Misalnya, jika model diberi contoh terjemahan teks dari bahasa Inggris ke bahasa Spanyol, model akan menggunakan contoh-contoh tersebut untuk memahami pola terjemahan dan menerapkannya pada teks baru.
- Generalisasi: Pembelajaran dari contoh terbatas mengandalkan kemampuan model uni-shot untuk menghasilkan output yang sesuai dengan pola yang diingin
- Penggunaan Konteks dan Struktur: Contoh prompt biasanya mencakup input-output yang diharapkan dan konteks dan struktur yang relevan. Hal ini membantu model memahami cara menangani variasi data. Ini juga membantu mereka menerapkan pengetahuan mereka ke tugas baru.

Keuntungan Few-Shot Learning:

- Efisiensi Data: Bahkan dengan data pelatihan yang terbatas, ini sangat berguna dalam kasus di mana data sulit didapat atau mahal untuk dikumpulkan.
- Fleksibilitas dan Adaptabilitas: Dapat diterapkan pada berbagai jenis tugas dan domain tanpa memerlukan pelatihan ulang yang mendalam.
- Waktu dan Sumber Daya: Mengurangi kebutuhan akan instruksi yang panjang dan penggunaan sumber daya komputasi yang besar.

Tantangan Few-Shot Learning:

- Keterbatasan Generalisasi: Meskipun model dapat belajar dari banyak contoh, mungkin sulit untuk menggeneralisasikannya ke data yang sangat berbeda atau baru.
- Kualitas Contoh: Kualitas dan relevansi contoh yang diberikan sangat berpengaruh pada efisiensi pembelajaran satu shot. Hasil yang tidak akurat dapat dihasilkan oleh contoh yang buruk atau tidak jelas.
- Tugas Kompleks: Beberapa contoh mungkin tidak cukup untuk mencapai performa yang tinggi jika tugasnya sangat kompleks atau membutuhkan pemahaman mendalam tentang konteksnya.

Pemahaman mendalam tentang few-shot learning memungkinkan kita untuk memanfaatkan model bahasa besar secara lebih efektif dalam berbagai aplikasi, terutama dalam situasi di mana data pelatihan terbatas. Pemahaman few-shot learning memungkinkan pengembangan aplikasi NLP yang lebih fleksibel dan efisien.

B. Penelitian Untuk Mengukur Efektivitas LLM

Dalam bab ini, berbagai eksperimen dilakukan untuk menilai kapasitas model bahasa besar (LLM) komersial dalam konteks prompting, zero-shot, dan few-shot learning. Tujuan eksperimen ini adalah untuk mengetahui bagaimana metode ini mempengaruhi kemanjuran dan ketepatan LLM dalam memberikan tanggapan yang tepat.

1. Eksperimen

   Eksperimen ini menggunakan dua LLM yang populer, Copilot GPT-4 dan Gemini. Itu menggunakan tugas jawaban pertanyaan, dengan zero-shot dan few-shot untuk setiap LLM yang digunakan.

2. Lakukan eksperimen melihat kemampuan penggunaan LLM

   Question Answering

   Data Question Answering

   Data diambil dari web:
   https://www.dexerto.com/valorant/all-vct-and-valorant-champions-winners-in-history-2186894/

All VCT and Valorant Champions winners

YEAR	TOURNAMENT	TEAM	ROSTER
2021	VCT Masters Reykjavík	Sentinels	ShahZaM, SicK, zombs, dapr, TenZ
2021	VCT Masters Berlin	Gambit Esports	d3ffo, Chronicle, nAts, Redgar, Sheydos
2021	Valorant Champions 2021	Acend	BONECOLD, cNed, Kiles, starxo, zeek
2022	VCT Masters Reykjavík	OpTic Gaming	FNS, Victor, crashies, yay, Marved
2022	VCT Masters Copenhagen	FunPlus Phoenix	ANGE1, Shao, Zyppan, SUYGETSU, ardiis
2022	Valorant Champions 2022	LOUD	pANcada, Sacy, Saadhak, aspas, Less
2023	VCT LOCK//IN	Fnatic	Boaster, Derke, Alfajer, Leo, Chronicle
2023	VCT Masters Tokyo	Fnatic	Boaster, Derke, Alfajer, Leo, Chronicle
2023	Valorant Champions	Evil Geniuses	jawgemo, Ethan, Boostio, C0M, Demon1
2024	VCT Masters Madrid	Sentinels	TenZ, Sacy, zekken, Zellsis, johnqt
2024	VCT Masters Shanghai	Gen.G	Meteor, t3xture, Lakia, Munchkin, Karon

Gambar 1. Data Team yang menjuarai turnamen VCT (Valorant Champions Tour) dari Masters hingga Champions.

1. Zero-shot

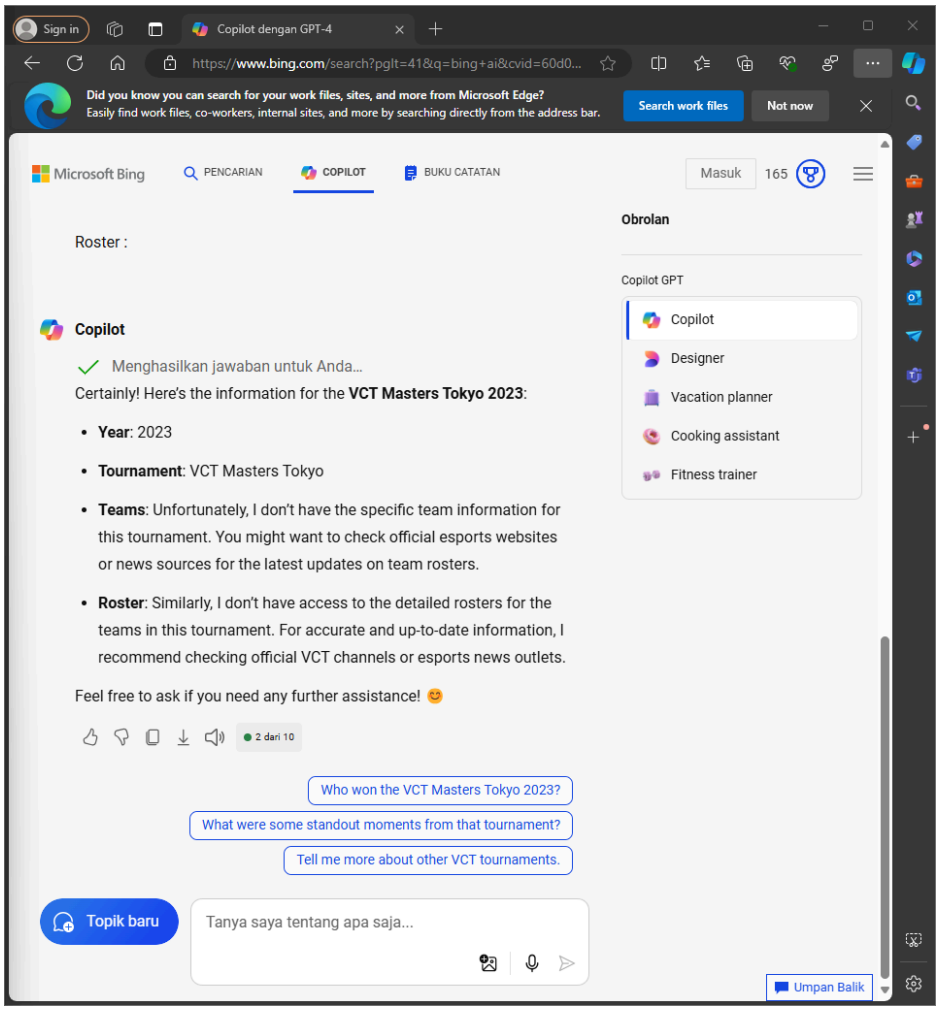

Gambar 2. Contoh penggunaan zero-shot learning pada kasus question answering menggunakan LLM Copilot GPT-4

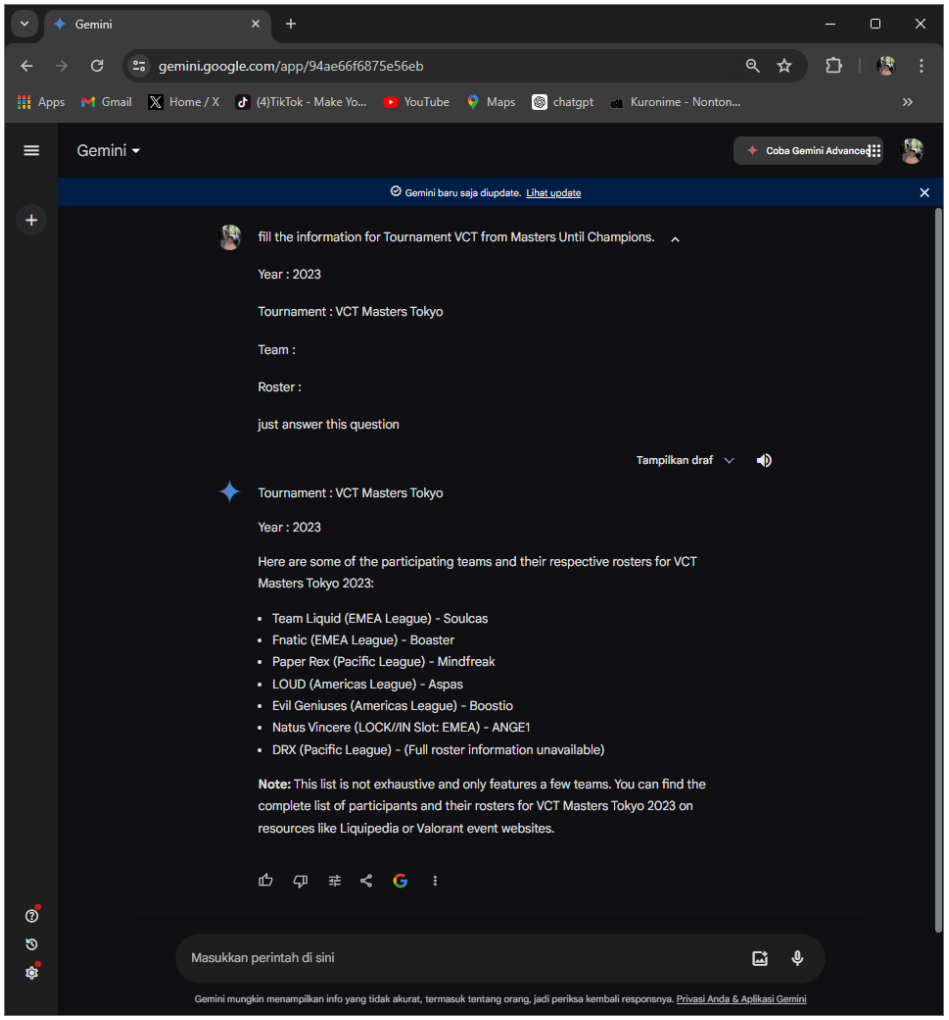

Gambar 3. Contoh penggunaan zero-shot learning pada kasus question answering menggunakan LLM gemini.

2. Few-shot

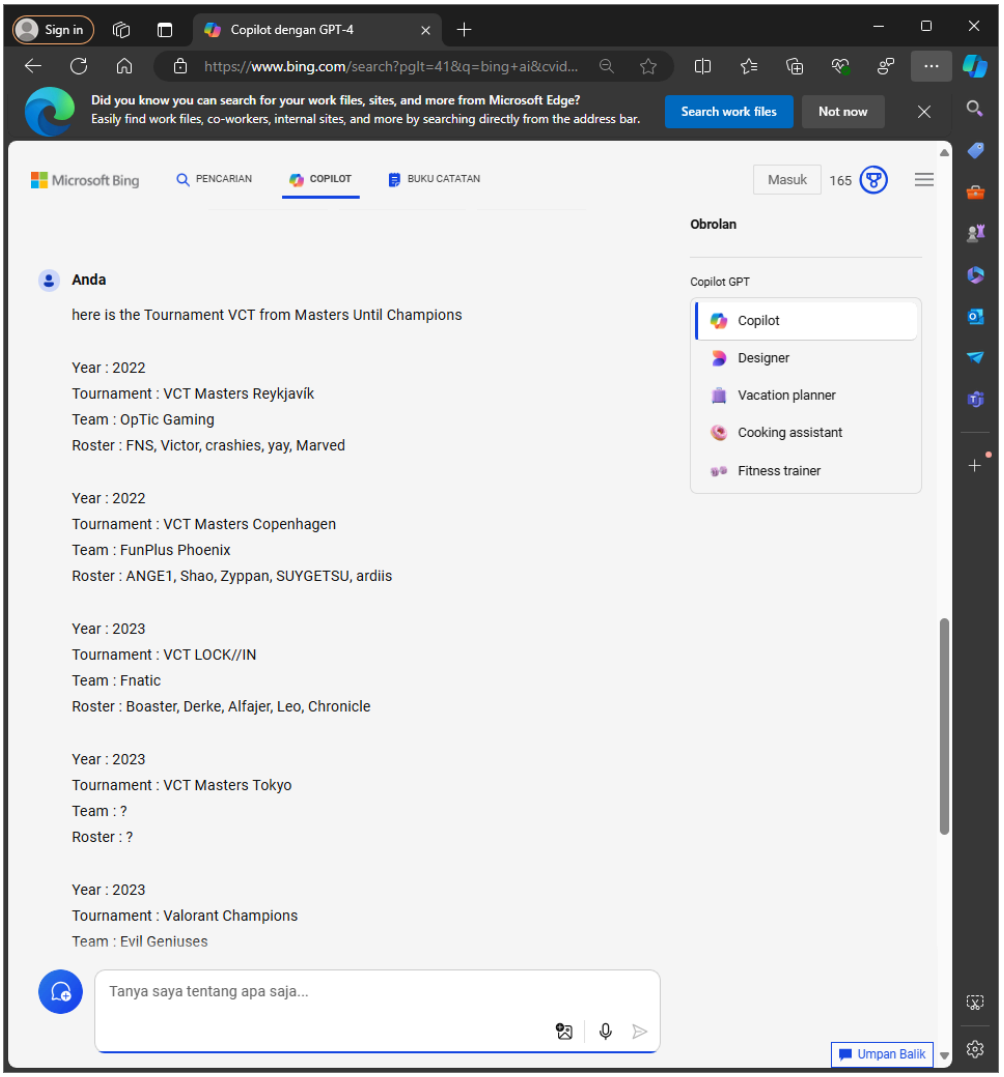

Gambar 4. Contoh penggunaan few-shot learning pada kasus question answering menggunakan LLM Copilot GPT-4

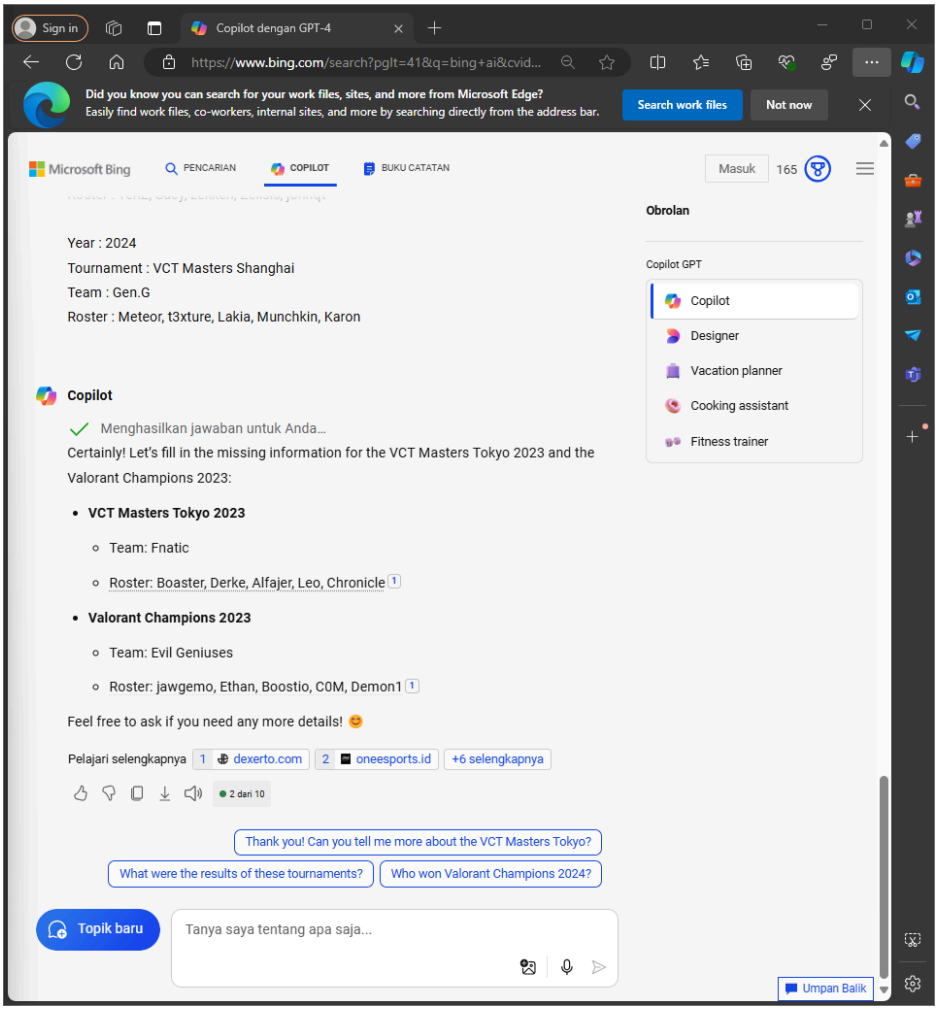

Gambar 5. Output dari pertanyaan pada Copilot GPT-4

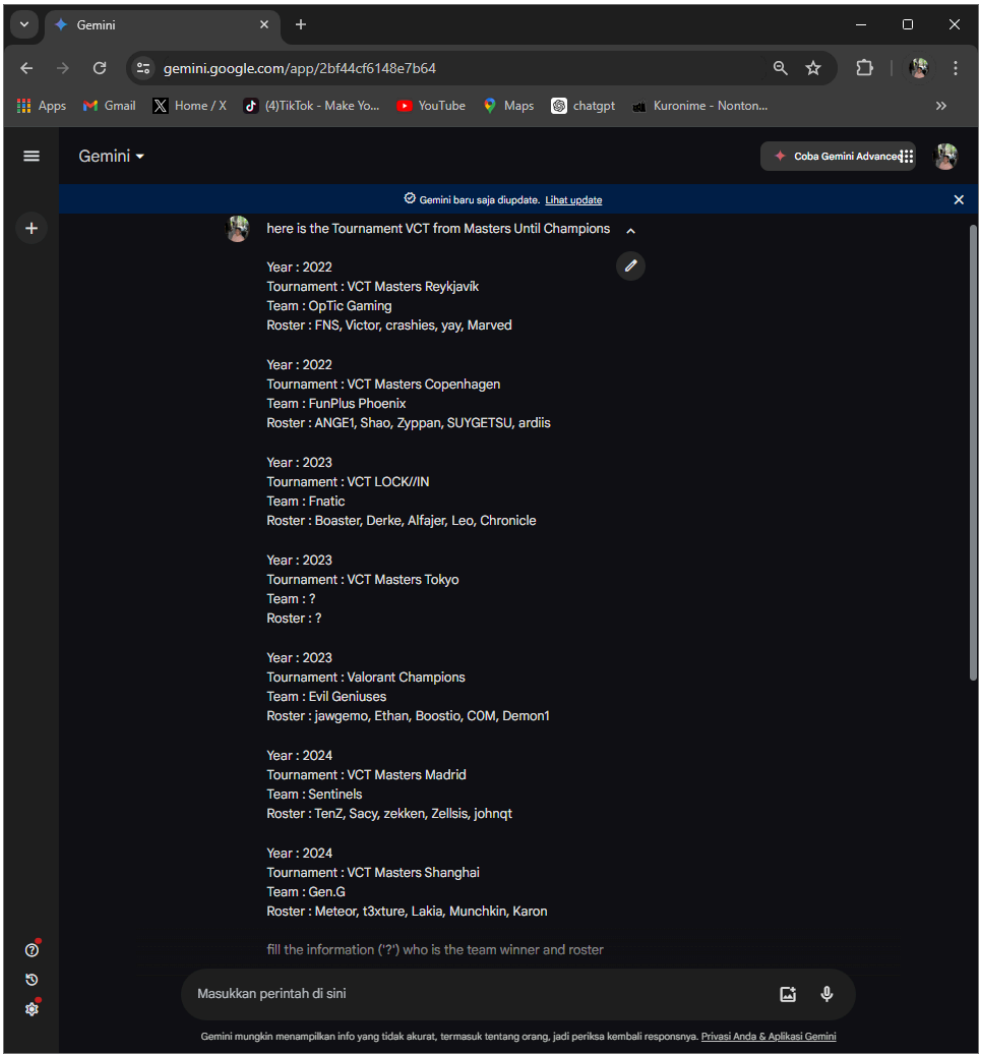

Gambar 6. Contoh penggunaan few-shot learning pada kasus question answering menggunakan LLM Gemini

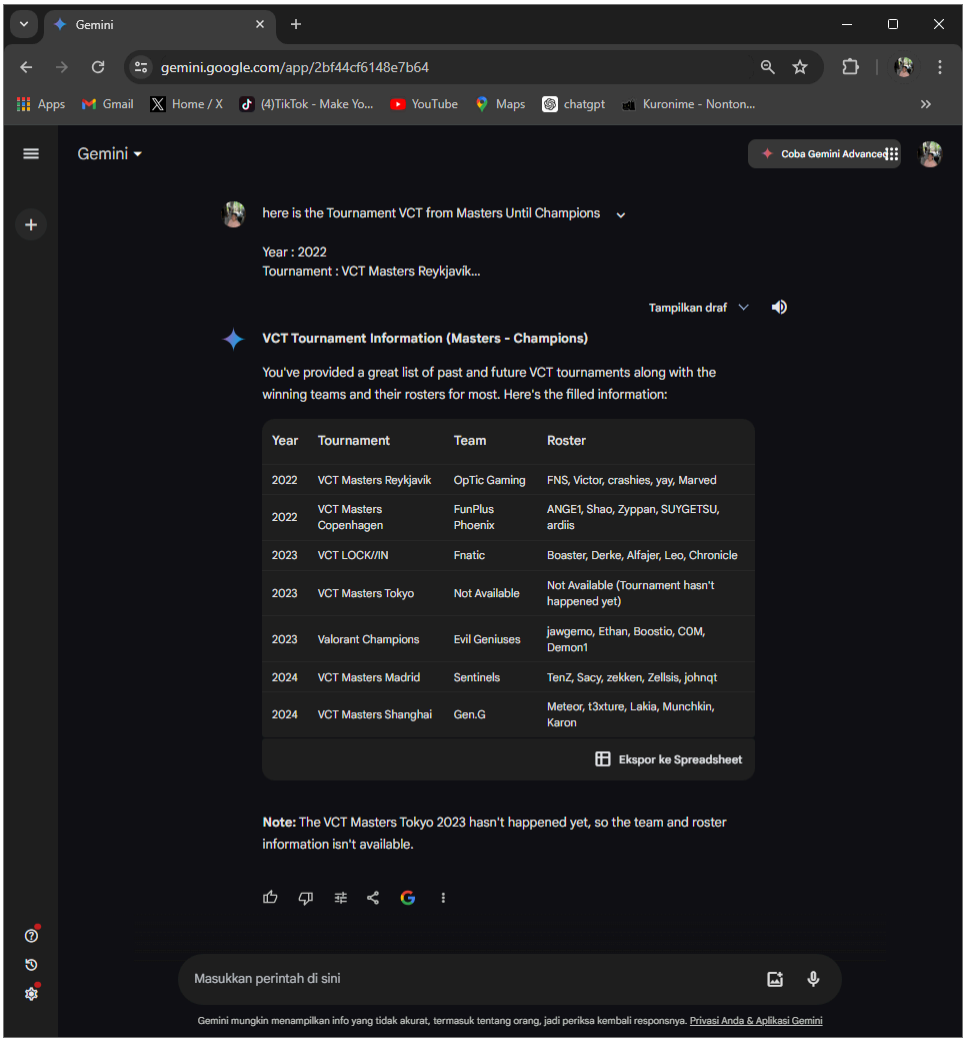

Gambar 7. Output dari pertanyaan pada Gemini

3. Analisis Hasil Eksperimen

Few-shot learning adalah pendekatan yang sangat efisien dan fleksibel dalam pembelajaran mesin, terutama dalam konteks model bahasa besar (LLM). Kemampuannya untuk memahami dan menyelesaikan tugas baru dengan hanya beberapa contoh pelatihan menjadikannya pilihan menarik untuk berbagai aplikasi NLP.

Dengan sedikit contoh pelatihan, model dapat belajar dan mengenali pola dari contoh tersebut, kemudian menggeneralisasikannya untuk menyelesaikan tugas serupa dengan akurat. Few-shot learning sangat adaptif dan responsif terhadap permintaan tugas, sambil tetap mempertahankan tingkat akurasi yang tinggi.

Meskipun LLM Gemini mungkin memiliki beberapa keterbatasan dalam memahami atau menghasilkan jawaban yang tepat, perkembangan terus dilakukan dalam iterasi berikutnya seperti LLM Copilot GPT-4. Dengan pembaruan dan iterasi baru, diharapkan LLM akan terus berkembang untuk mengatasi tantangan dan meningkatkan kualitas respons yang dihasilkan. Setiap model memiliki kekuatan dan kelemahan uniknya sendiri, dan terus ada ruang untuk perbaikan dan peningkatan performa.

Referensi

Radford, A., et al. (2019). "Language Models are Unsupervised Multitask Learners."

Liu, P. J., et al. (2021). "Pre-train, Prompt, and Predict: A Systematic Survey of Prompting Methods in Natural Language Processing." arXiv preprint arXiv:2107.13586.

Brown, T. B., et al. (2020). "Language Models are Few-Shot Learners." arXiv preprint arXiv:2005.14165.

Schick, T., & Schütze, H. (2021). "It's Not Just Size That Matters: Small Language Models Are Also Few-Shot Learners." arXiv preprint arXiv:2009.07118.